

TRƯỜNG ĐẠI HỌC SƯ PHẠM KỸ THUẬT HƯNG YÊN
KHOA CÔNG NGHỆ THÔNG TIN

-----***-----

BÁO CÁO BÀI TẬP LỚN
MÔN HỌC: HỌC MÁY CƠ BẢN

ĐỀ TÀI:
DỰ ĐOÁN MỨC TIÊU HAO NHIÊN LIỆU CỦA
XE

Giảng viên hướng dẫn: [GIẢNG VIÊN HƯỚNG DẪN]
Sinh viên thực hiện: [HỌ TÊN SINH VIÊN]
Mã sinh viên: [MÃ SINH VIÊN]
Lớp: [LỚP]

Hưng Yên, Năm 2026

TRƯỜNG ĐẠI HỌC SƯ PHẠM KỸ THUẬT HƯNG YÊN
KHOA CÔNG NGHỆ THÔNG TIN

BÁO CÁO BÀI TẬP LỚN MÔN HỌC MÁY CƠ BẢN

DỰ ĐOÁN MỨC TIÊU HAO NHIÊN LIỆU CỦA XE

Cán bộ chấm thi 1:

Cán bộ chấm thi 2:

Hưng Yên, Năm 2026

NHẬN XÉT CỦA GIẢNG VIÊN HƯỚNG DẪN

Nhận xét của giảng viên hướng dẫn:

.....

.....

.....

.....

.....

.....

.....

.....

Hưng Yên, ngày tháng năm 2026

Giảng viên hướng dẫn

(Ký và ghi rõ họ tên)

LỜI CAM ĐOAN

Em xin cam đoan báo cáo bài tập lớn môn học Học máy cơ bản với đề tài "Dự đoán mức tiêu hao nhiên liệu của xe" là công trình nghiên cứu và thực hiện độc lập của nhóm chúng em dưới sự hướng dẫn chuyên môn của giảng viên. Các nội dung phân tích, dữ liệu thực nghiệm, kết quả đánh giá mô hình và thông tin hệ thống được trình bày trong báo cáo là hoàn toàn trung thực, khách quan và được trích xuất trực tiếp từ quá trình triển khai dự án thực tế.

Toàn bộ các tài liệu tham khảo, dữ liệu nguồn được khai thác từ cơ sở dữ liệu mở công khai (Chính phủ Canada / Kaggle) đã được trích dẫn đầy đủ nguồn gốc và tuân thủ đúng quy định về bản quyền. Chúng em xin chịu hoàn toàn trách nhiệm trước bộ môn và nhà trường về tính chính xác, trung thực của các thông tin được trình bày trong báo cáo này.

Hưng Yên, ngày tháng năm 2026

Đại diện nhóm sinh viên thực hiện

[HỌ TÊN SINH VIÊN]

LỜI CẢM ƠN

Lời đầu tiên, chúng em xin gửi lời cảm ơn chân thành và sâu sắc nhất đến các Thầy, Cô giáo trong Khoa Công nghệ thông tin - Trường Đại học Sư phạm Kỹ thuật Hưng Yên đã giảng dạy, truyền đạt những kiến thức lý thuyết nền tảng vô cùng quý báu và định hướng tư duy khoa học cho chúng em trong suốt quá trình học tập môn Học máy cơ bản.

Đặc biệt, chúng em xin trân trọng cảm ơn giảng viên hướng dẫn môn học đã tận tình chỉ bảo, đưa ra những nhận xét, góp ý định hướng chuyên môn định kỳ giúp chúng em hoàn thiện phương pháp luận nghiên cứu, kỹ năng xử lý dữ liệu và xây dựng mô hình học máy đạt hiệu quả cao.

Mặc dù chúng em đã nỗ lực hết sức để hoàn thiện báo cáo một cách chu đáo, khoa học và bám sát thực tế dự án, song do hạn chế về kinh nghiệm thực tiễn nên khó tránh khỏi những thiếu sót nhất định. Chúng em rất mong tiếp tục nhận được những ý kiến đóng góp, phản hồi quý báu từ các Thầy, Cô để báo cáo và sản phẩm của chúng em ngày càng hoàn thiện hơn.

Chúng em xin chân thành cảm ơn!

MỤC LỤC

CHƯƠNG 1: TỔNG QUAN VỀ ĐỀ TÀI

- 1.1. Lý do chọn đề tài
- 1.2. Mục tiêu đề tài
- 1.3. Đối tượng nghiên cứu
- 1.4. Phạm vi nghiên cứu
- 1.5. Nội dung thực hiện
- 1.6. Phương pháp tiếp cận

CHƯƠNG 2: CƠ SỞ LÝ THUYẾT

- 2.1. Tổng quan Machine Learning
- 2.2. Học máy có giám sát
- 2.3. Bài toán hồi quy
- 2.4. Phát biểu bài toán dự đoán tiêu hao nhiên liệu
- 2.5. Linear Regression
- 2.6. Decision Tree Regressor
- 2.7. K-Nearest Neighbors Regression
- 2.8. Support Vector Regression
- 2.9. So sánh nguyên lý 4 mô hình
- 2.10. Các chỉ số đánh giá
- 2.11. Overfitting và Underfitting
- 2.12. Cross Validation và tinh chỉnh siêu tham số

CHƯƠNG 3: DỮ LIỆU VÀ TIỀN XỬ LÝ

- 3.1. Giới thiệu bộ dữ liệu
- 3.2. Danh sách thuộc tính
- 3.3. Xác định biến mục tiêu
- 3.4. Lựa chọn đặc trưng đầu vào
- 3.5. Kiểm tra nguy cơ rò rỉ dữ liệu (Data Leakage)
- 3.6. Phân tích dữ liệu ban đầu
- 3.7. Phân tích khám phá dữ liệu (EDA)
- 3.8. Phân tích biến mục tiêu
- 3.9. Phân tích mối quan hệ đặc trưng – mục tiêu
- 3.10. Tiền xử lý dữ liệu
- 3.11. Encoding dữ liệu phân loại

- 3.12. Chuẩn hóa dữ liệu
- 3.13. Chia dữ liệu huấn luyện và kiểm tra
- 3.14. Tránh Data Leakage trong tiền xử lý

CHƯƠNG 4: XÂY DỰNG, HUẤN LUYỆN VÀ ĐÁNH GIÁ MÔ HÌNH

- 4.1. Quy trình xây dựng mô hình
- 4.2. Mô hình cơ sở (Baseline Model)
- 4.3. Linear Regression
- 4.4. Decision Tree Regressor
- 4.5. KNN Regression
- 4.6. Support Vector Regression
- 4.7. Bảng siêu tham số thử nghiệm và được chọn
- 4.8. Kết quả Cross Validation
- 4.9. Tiêu chí đánh giá
- 4.10. Kết quả Linear Regression
- 4.11. Kết quả Decision Tree Regressor
- 4.12. Kết quả KNN Regression
- 4.13. Kết quả Support Vector Regression
- 4.14. Bảng so sánh tổng hợp 4 mô hình
- 4.15. Phân tích Actual vs Predicted
- 4.16. Residual Analysis (Phân tích phần dư)
- 4.17. Phân tích Overfitting / Underfitting
- 4.18. So sánh 4 mô hình
- 4.19. Lựa chọn mô hình cuối

CHƯƠNG 5: XÂY DỰNG HỆ THỐNG, KIỂM THỬ VÀ KẾT LUẬN

- 5.1. Tích hợp mô hình vào hệ thống
- 5.2. Kiến trúc tổng thể
- 5.3. Giao diện nhập thông tin xe
- 5.4. Quy trình dự đoán
- 5.5. Ý nghĩa kết quả dự đoán
- 5.6. Triển khai hệ thống
- 5.7. Kiểm thử dữ liệu hợp lệ
- 5.8. Kiểm thử dữ liệu không hợp lệ
- 5.9. Kiểm thử hệ thống tổng thể

- 5.10. Kiểm thử hiệu năng
- 5.11. Kết quả đạt được
- 5.12. Hạn chế
- 5.13. Hướng phát triển
- 5.14. Kết luận chung

PHẦN SAU BÁO CÁO

PHÂN CÔNG CÔNG VIỆC

TÀI LIỆU THAM KHẢO

PHỤ LỤC

DANH SÁCH TỪ VIẾT TẮT

Từ viết tắt	Giải nghĩa tiếng Anh / Tiếng Việt
AI	Artificial Intelligence - Trí tuệ nhân tạo
ML	Machine Learning - Học máy
EDA	Exploratory Data Analysis - Phân tích khám phá dữ liệu
MAE	Mean Absolute Error - Sai số tuyệt đối trung bình
MSE	Mean Squared Error - Sai số bình phương trung bình
RMSE	Root Mean Squared Error - Căn bậc hai sai số bình phương trung bình
R^2	Coefficient of Determination - Hệ số xác định
KNN	K-Nearest Neighbors - K láng giềng gần nhất
SVR	Support Vector Regression - Hồi quy vector hỗ trợ

DANH SÁCH HÌNH ẢNH

- Hình 3. 1: Phân bố biến mục tiêu mức tiêu hao nhiên liệu kết hợp (target_distribution.png)
- Hình 3. 2: Biểu đồ Boxplot nhận diện ngoại lệ của biến mục tiêu (target_boxplot.png)
- Hình 3. 3: Mối quan hệ giữa dung tích động cơ và mức tiêu hao nhiên liệu (engine_size_vs_target.png)

Hình 3. 4: Mức tiêu hao nhiên liệu theo số lượng xi-lanh (cylinders_vs_target.png)

Hình 3. 5: Mức tiêu hao nhiên liệu theo phân loại lớp xe (vehicle_class_vs_target.png)

Hình 3. 6: Mức tiêu hao nhiên liệu theo loại nhiên liệu sử dụng (fuel_type_vs_target.png)

Hình 3. 7: Ma trận tương quan Pearson giữa các đặc trưng số (correlation_heatmap.png)

Hình 3. 8: Biểu đồ kiểm tra tỷ lệ dữ liệu khuyết thiếu (missing_values.png)

Hình 4. 1: Biểu đồ so sánh hiệu năng MAE, RMSE và R^2 giữa 4 mô hình (model_comparison.png)

Hình 4. 2: Biểu đồ giá trị thực tế vs giá trị dự đoán Actual vs Predicted (actual_vs_predicted.png)

Hình 4. 3: Biểu đồ phân tích phần dư Residual Plot của các mô hình (residual_plot.png)

CHƯƠNG 1: TỔNG QUAN VỀ ĐỀ TÀI

1.1. Lý do chọn đề tài

Trong bối cảnh ngành công nghiệp giao thông vận tải phát triển bùng nổ, ô tô tiếp tục đóng vai trò là phương tiện di chuyển chính yếu cho cá nhân và vận tải hàng hóa. Tuy nhiên, các dòng xe khác nhau sở hữu cấu hình kỹ thuật (dung tích động cơ, số xi-lanh, công nghệ hộp số, loại nhiên liệu) có mức tiêu thụ nhiên liệu chênh lệch rất lớn. Mức tiêu thụ nhiên liệu không chỉ ảnh hưởng trực tiếp tới chi phí vận hành hàng ngày của người sở hữu xe mà còn liên quan chặt chẽ tới hiệu quả sử dụng năng lượng quốc gia và mức độ phát thải khí nhà kính (CO_2 , NO_x) gây biến đổi khí hậu.

Việc nắm bắt và dự đoán chính xác mức tiêu hao nhiên liệu của phương tiện dựa trên các thông số thiết kế kỹ thuật có ý nghĩa hết sức quan trọng. Đối với người tiêu dùng, chỉ số này giúp họ đưa ra quyết định mua sắm kinh tế và phù hợp với nhu cầu. Đối với các nhà quản lý giao thông và doanh nghiệp vận tải, việc phân tích dữ liệu tiêu hao giúp tối ưu hóa chi phí nhiên liệu và xây dựng chính sách phát triển phương tiện thân thiện với môi trường.

Dữ liệu lịch sử kiểm định nhiên liệu ô tô qua các năm cung cấp lượng thông tin phong phú về mối quan hệ giữa các đặc tính thiết kế và hiệu suất tiêu thụ năng lượng. Phương pháp Học máy (Machine Learning) với khả năng tự động khai phá các mối quan hệ phi tuyến phức tạp từ dữ liệu lịch sử là công cụ hoàn hảo để giải quyết bài toán này. Đầu ra của mô hình là một giá trị định lượng liên tục (mức tiêu hao nhiên liệu tính bằng Lít/100 km), do đó đề tài được xây dựng theo bài toán Hồi quy (Regression) mang tính thực tiễn cao.

1.2. Mục tiêu đề tài

1.2.1. Mục tiêu tổng quát

Nghiên cứu, xây dựng và đánh giá các mô hình học máy hồi quy nhằm dự đoán chính xác mức tiêu hao nhiên liệu kết hợp của xe ô tô dựa trên các thông số đặc trưng kỹ thuật, đồng thời tích hợp mô hình tối ưu vào một hệ thống dự đoán ứng dụng thực tế có giao diện tương tác người dùng.

1.2.2. Mục tiêu cụ thể

- Khai phá và hiểu rõ bản chất bộ dữ liệu kiểm định tiêu thụ nhiên liệu xe ô tô (MY1995-2023 Fuel Consumption Ratings).

- Phân tích thống kê và trực quan hóa mối quan hệ giữa các thông số kỹ thuật xe và mức tiêu thụ nhiên liệu.
- Thực hiện tiền xử lý dữ liệu chuẩn xác, bao gồm xử lý trùng lặp, mã hóa biến phân loại (Encoding) và chuẩn hóa biến số (Scaling).
- Phân tích và ngăn ngừa triệt để nguy cơ rò rỉ dữ liệu (Data Leakage) bằng cách loại bỏ các thuộc tính trực tiếp hoặc gián tiếp tiết lộ giá trị mục tiêu.
- Xây dựng và kiểm thử 4 mô hình hồi quy kinh điển: Linear Regression, Decision Tree Regressor, K-Nearest Neighbors Regressor (KNN) và Support Vector Regression (SVR).
- Thực hiện tinh chỉnh siêu tham số (Hyperparameter Tuning) thông qua kiểm định chéo (5-Fold Cross Validation) trên tập huấn luyện.
- Đánh giá và so sánh hiệu năng các mô hình bằng bộ tiêu chí hồi quy chuẩn xác (MAE, MSE, RMSE, R^2) cùng thời gian suy luận.
- Lựa chọn mô hình tối ưu nhất và tích hợp vào hệ thống phần mềm dự đoán đa tầng hoàn chỉnh.
- Thực hiện kiểm thử dữ liệu và kiểm thử hệ thống nhằm bảo đảm khả năng hoạt động ổn định và chính xác.

1.3. Đối tượng nghiên cứu

Đối tượng nghiên cứu của đề tài là tập dữ liệu tiêu thụ nhiên liệu ô tô thực tế từ năm 1995 đến năm 2023 (MY1995-2023 Fuel Consumption Ratings) do Chính phủ Canada phát hành chính thức trên nền tảng dữ liệu Kaggle. Dữ liệu bao gồm các thông số kỹ thuật của 26,998 dòng xe (sau khi làm sạch trùng lặp) và chỉ số tiêu hao nhiên liệu kết hợp tương ứng.

1.4. Phạm vi nghiên cứu

- Dữ liệu nghiên cứu: Các dòng ô tô sản xuất và kiểm định trong giai đoạn từ năm 1995 đến năm 2023.
- Biến mục tiêu (Target): Mức tiêu hao nhiên liệu kết hợp (Fuel Consumption Comb), biểu diễn bằng đơn vị L/100 km.
- Phương pháp chuyên môn: Bài toán Hồi quy (Regression) trong Học máy có giám sát (Supervised Learning).

- Thuật toán nghiên cứu: Tập trung thử nghiệm và so sánh 4 mô hình: Linear Regression, Decision Tree Regressor, K-Nearest Neighbors Regressor (KNN) và Support Vector Regression (SVR).

1.5. Nội dung thực hiện

Đề tài được tiến hành qua các giai đoạn mạch lạc: Thu thập dữ liệu -> Phân tích khám phá EDA -> Tiền xử lý & Chọn đặc trưng -> Phân chia tập dữ liệu 80/20 -> Huấn luyện 4 mô hình -> Tính chính siêu tham số qua Cross Validation -> Đánh giá & So sánh mô hình -> Lựa chọn mô hình tối ưu -> Tích hợp hệ thống -> Kiểm thử toàn diện -> Kết luận.

1.6. Phương pháp tiếp cận

Đề tài tiếp cận bài toán theo quy trình chuẩn mực của các dự án Data Science & Machine Learning: Kết hợp phân tích thống kê mô tả (Descriptive Statistics), trực quan hóa dữ liệu (Data Visualization), xây dựng Pipeline tiền xử lý tự động, áp dụng phương pháp Cross Validation chống quá khớp (Overfitting) và thiết kế hệ thống phần mềm tách biệt giữa dịch vụ trí tuệ nhân tạo và dịch vụ xử lý nghiệp vụ.

CHƯƠNG 2: CƠ SỞ LÝ THUYẾT

2.1. Tổng quan Machine Learning

Học máy (Machine Learning - ML) là một phân nhánh quan trọng của Trí tuệ nhân tạo (AI), nghiên cứu các thuật toán có khả năng tự động cải thiện hiệu năng giải quyết bài toán thông qua việc 'học' từ dữ liệu kinh nghiệm mà không cần phải được lập trình thủ công quy tắc cứng cho từng trường hợp. Mô hình học máy thiết lập mối quan hệ toán học giữa không gian đặc trưng đầu vào X và đầu ra y , từ đó đưa ra dự đoán chính xác trên các dữ liệu mới chưa từng xuất hiện.

2.2. Học máy có giám sát

Học máy có giám sát (Supervised Learning) là phương pháp huấn luyện mô hình dựa trên tập dữ liệu đã được dán nhãn (Labeled Dataset) bao gồm các cặp (X_i, y_i) , trong đó X_i là vector chứa các đặc trưng đầu vào và y_i là giá trị mục tiêu tương ứng. Thuật toán điều chỉnh các tham số nội tại của mô hình nhằm tối thiểu hóa hàm mất mát (Loss Function), giúp mô hình ánh xạ từ X sang y một cách chuẩn xác nhất.

2.3. Bài toán hồi quy

Bài toán Hồi quy (Regression) trong học máy có giám sát được định nghĩa khi giá trị mục tiêu y là một biến số thực liên tục ($y \in \mathbb{R}$). Khác với bài toán Phân loại (Classification) có đầu ra là các nhãn danh định rời rạc, bài toán hồi quy nhằm ước lượng chính xác một đại lượng định lượng. Trong đề tài này, mức tiêu hao nhiên liệu của xe là giá trị định lượng đo bằng Lít/100 km, do đó hoàn toàn phù hợp với bản chất bài toán hồi quy.

2.4. Phát biểu bài toán dự đoán tiêu hao nhiên liệu

- Đầu vào (Input X): Vector 7 thuộc tính kỹ thuật của xe bao gồm: Năm sản xuất (Model Year), Hãng sản xuất (Make), Phân loại loại xe (Vehicle Class), Dung tích động cơ (Engine Size), Số lượng xi-lanh (Cylinders), Loại hộp số (Transmission), và Loại nhiên liệu (Fuel Type).

- Đầu ra (Output y): Mức tiêu hao nhiên liệu kết hợp của xe (Fuel Consumption Comb), biểu diễn theo đơn vị L/100 km.

2.5. Linear Regression

Hồi quy tuyến tính (Linear Regression) là mô hình nền tảng giả định mối quan hệ tuyến tính giữa các đặc trưng đầu vào X và biến mục tiêu y :

$$y_{\text{pred}} = w_0 + w_1 * x_1 + w_2 * x_2 + \dots + w_p * x_p$$

Trong đó w_0 là hệ số tự do (intercept) và w_i là các trọng số (coefficients). Thuật toán tìm kiếm bộ trọng số bằng phương pháp Bình phương tối thiểu (Ordinary Least Squares - OLS) nhằm tối thiểu hóa tổng bình phương sai số. Ưu điểm của mô hình là tốc độ tính toán cực nhanh, dễ giải thích ý nghĩa hệ số, nhưng hạn chế ở khả năng biểu diễn các mối quan hệ phi tuyến phức tạp.

2.6. Decision Tree Regressor

Hồi quy Cây quyết định (Decision Tree Regressor) phân chia không gian dữ liệu đầu vào thành các vùng hình chữ nhật không chồng lấn bằng các câu hỏi điều kiện tại mỗi nút trong (internal node). Giá trị dự đoán tại nút lá (leaf node) là giá trị trung bình của các mẫu huấn luyện rơi vào vùng đó. Tiêu chuẩn chia nút dựa trên mức độ giảm chỉ số MSE hoặc MAE. Mô hình có khả năng bắt kịp các mối quan hệ phi tuyến mà không cần chuẩn hóa dữ liệu, tuy nhiên rất dễ bị quá khớp (Overfitting) nếu cây phát triển quá sâu mà không khống chế các siêu tham số như độ sâu tối đa (max_depth) hay số mẫu tối thiểu tại lá (min_samples_leaf).

2.7. K-Nearest Neighbors Regression

Hồi quy K láng giềng gần nhất (KNN Regressor) là thuật toán học lười (Lazy Learning). Khi cần dự đoán một điểm dữ liệu mới, thuật toán tính khoảng cách (khoảng cách Euclidean hoặc Manhattan) từ điểm đó tới toàn bộ các điểm trong tập huấn luyện để chọn ra K điểm gần nhất. Giá trị dự đoán được tính bằng trung bình (hoặc trung bình có trọng số theo khoảng cách) giá trị y của K láng giềng. KNN nhạy cảm cao với thang đo dữ liệu, do đó bắt buộc phải chuẩn hóa đặc trưng (Scaling) trước khi huấn luyện.

2.8. Support Vector Regression

Hồi quy Vector hỗ trợ (Support Vector Regression - SVR) mở rộng từ thuật toán SVM. SVR tìm kiếm một siêu phẳng dự đoán nằm trong dải lề epsilon (epsilon-insensitive tube), nơi các sai số nhỏ hơn epsilon không bị phạt. Với các bài toán phi tuyến, SVR áp dụng kỹ thuật Kernel (như Radial Basis Function - RBF Kernel) để chiếu dữ liệu lên không gian nhiều chiều hơn, giúp tìm siêu phẳng tuyến

tính trong không gian mới. Tham số điều hòa C kiểm soát sự đánh đổi giữa độ phẳng của siêu phẳng và mức độ chấp nhận sai số ngoài dải lề.

2.9. So sánh nguyên lý 4 mô hình

Tiêu chí so sánh	Linear Regression	Decision Tree	KNN Regressor	SVR (RBF Kernel)
Bản chất mô hình	Tuyến tính tham số	Phi tuyến phi tham số	Dựa trên khoảng cách	Phi tuyến biên siêu phẳng
Mô hình hóa phi tuyến	Hạn chế	Rất tốt	Khá tốt	Rất tốt (nhờ RBF Kernel)
Yêu cầu chuẩn hóa	Khuyến dùng	Không bắt buộc	BẮT BUỘC	BẮT BUỘC
Siêu tham số chính	fit_intercept	max_depth, min_samples_split	n_neighbors, weights, p	C, epsilon, kernel, gamma

2.10. Các chỉ số đánh giá

- Sai số tuyệt đối trung bình (MAE):

$$MAE = (1 / n) * \sum(|y_i - y_{pred_i}|)$$

MAE đo lường độ lớn trung bình của các sai số dự đoán theo đúng đơn vị của biến mục tiêu (L/100 km). MAE càng nhỏ mô hình càng chính xác.

- Sai số bình phương trung bình (MSE) & Căn bậc hai sai số bình phương trung bình (RMSE):

$$RMSE = \sqrt{(1 / n) * \sum((y_i - y_{pred_i})^2)}$$

RMSE trừng phạt nặng hơn đối với các sai số lớn (outliers) do có phép bình phương trước khi lấy căn. Chỉ số RMSE càng thấp thể hiện mô hình ít mắc phải sai số nghiêm trọng.

- Hệ số xác định (R² Score):

$$R^2 = 1 - [\sum((y_i - y_{pred_i})^2) / \sum((y_i - y_{mean})^2)]$$

R² đo lường tỷ lệ biến thiên của biến mục tiêu được giải thích bởi mô hình. R² tiến gần tới 1.0 (100%) thể hiện mô hình giải thích dữ liệu cực kỳ tốt.

2.11. Overfitting và Underfitting

Quá khớp (Overfitting) xảy ra khi mô hình học quá mức các chi tiết và nhiễu (noise) của tập huấn luyện, dẫn đến kết quả rất cao trên tập Train nhưng kém trên

tập Test. Ngược lại, Chưa khớp (Underfitting) xảy ra khi mô hình quá đơn giản, không học đủ cấu trúc của dữ liệu. Việc theo dõi chênh lệch điểm R^2 giữa tập Train và tập Test giúp phát hiện và ngăn ngừa hiện tượng này.

2.12. Cross Validation và tinh chỉnh siêu tham số

Phương pháp Kiểm định chéo K phát (K-Fold Cross Validation) chia tập huấn luyện thành K phần bằng nhau. Mô hình được huấn luyện trên K-1 phần và đánh giá trên 1 phần còn lại, lặp lại K lần. Kỹ thuật Grid Search thử nghiệm toàn bộ các kết hợp siêu tham số trên lưới để chọn ra cấu hình có điểm MAE CV trung bình tốt nhất, đảm bảo tính khách quan trước khi đánh giá lần cuối trên tập Test.

CHƯƠNG 3: DỮ LIỆU VÀ TIỀN XỬ LÝ

3.1. Giới thiệu bộ dữ liệu

Bộ dữ liệu thực tế được sử dụng trong đề tài có tên chính thức là MY1995-2023 Fuel Consumption Ratings, được công bố chính thức bởi Chính phủ Canada (Government of Canada) trên nền tảng dữ liệu Kaggle theo giấy phép Open Government Licence - Canada. Bộ dữ liệu tổng hợp kết quả kiểm định tiêu thụ nhiên liệu tiêu chuẩn của các phương tiện giao thông qua 29 năm (từ 1995 đến 2023). Tập dữ liệu gốc chứa 27,001 bản ghi; sau quá trình làm sạch loại bỏ 3 bản ghi trùng lặp hoàn toàn, tập dữ liệu chính thức còn lại đúng 26,998 bản ghi hợp lệ.

3.2. Danh sách thuộc tính

STT	Tên thuộc tính	Kiểu dữ liệu	Ý nghĩa / Khoảng giá trị	Vai trò
1	Model Year	Số nguyên (Integer)	Năm sản xuất xe (1995 - 2023)	Input Feature
2	Make	Phân loại (Category)	Hãng sản xuất xe (55 hãng chuẩn hóa)	Input Feature
3	Vehicle Class	Phân loại (Category)	Phân loại phân khúc/dáng xe (25 loại)	Input Feature
4	Engine Size (L)	Số thực (Float)	Dung tích động cơ tính bằng Lít (0.8 - 8.4 L)	Input Feature
5	Cylinders	Số nguyên (Integer)	Số lượng xy-lanh động cơ (2 - 16 xy-lanh)	Input Feature
6	Transmission	Phân loại (Category)	Mã kiểu hộp số (30 kiểu: A4, AS6, M6, AV...)	Input Feature
7	Fuel Type	Phân loại (Category)	Loại nhiên liệu (5 loại: X, Z, D, E, N)	Input Feature
8	Fuel Consumption Comb	Số thực (Float)	Tiêu thụ nhiên liệu kết hợp (4.0 - 26.1 L/100km)	Target (Biến mục tiêu)

3.3. Xác định biến mục tiêu

Biến mục tiêu (Target) của bài toán được xác định chính xác là Mức tiêu hao nhiên liệu kết hợp (Fuel Consumption Comb), biểu diễn theo đơn vị Lít/100 km (L/100 km). Trong dữ liệu thực tế, chỉ số này có giá trị trung bình là 10.9 L/100 km, giá trị nhỏ nhất là 4.0 L/100 km (các dòng xe hybrid/tiết kiệm) và giá trị lớn nhất là 26.1 L/100 km (các dòng xe siêu thể thao hoặc xe tải trọng lớn).

3.4. Lựa chọn đặc trưng đầu vào

Project lựa chọn 7 đặc trưng đầu vào chuẩn hóa (Canonical Features) phản ánh toàn diện bản chất kỹ thuật xe: Model Year, Make, Vehicle Class, Engine Size (L), Cylinders, Transmission, và Fuel Type. Các thuộc tính này có đầy đủ trên mọi tệp dữ liệu lịch sử và dễ dàng thu thập từ người dùng khi triển khai hệ thống.

3.5. Kiểm tra nguy cơ rò rỉ dữ liệu (Data Leakage)

Một nội dung quan trọng trong quy trình xử lý dữ liệu của project là phân tích và loại bỏ các thuộc tính gây nguy cơ rò rỉ dữ liệu (Data Leakage) hoặc dư thừa thông tin nghiêm trọng. Cụ thể:

- Loại bỏ Fuel Consumption City và Fuel Consumption Hwy: Hai chỉ số tiêu thụ trong thành phố và trên cao tốc trực tiếp cấu thành chỉ số tiêu thụ kết hợp theo công thức trọng số. Nếu giữ lại, mô hình sẽ học được mối quan hệ toán học trực tiếp này (Proxy target), dẫn đến kết quả đánh giá cao ảo nhưng không có khả năng dự đoán từ thông số kỹ thuật xe.

- Loại bỏ Fuel Consumption Comb (mpg): Đây là phép chuyển đổi đơn vị 1-1 trực tiếp từ L/100 km sang Miles Per Gallon.

- Loại bỏ CO2 Emissions (g/km): Lượng phát thải CO2 được các cơ quan kiểm định tính toán theo hàm tuyến tính trực tiếp từ mức nhiên liệu tiêu thụ.

- Loại bỏ CO2 Rating và SmogRating: Tỷ lệ khuyết thiếu dữ liệu cực lớn (~70.3% và ~74.4% khuyết thiếu do chỉ có từ các đời xe gần đây), đồng thời trực tiếp phản ánh mức tiêu thụ.


- Loại bỏ thuộc tính Model: Tên model có độ mịn quá cao (4,815 tên riêng lẻ), nếu đưa vào mã hóa One-Hot sẽ tạo ra hàng nghìn cột thừa gây ra hiện tượng quá khớp (Overfitting) nghiêm trọng.

3.6. Phân tích dữ liệu ban đầu

Kết quả kiểm tra dữ liệu ban đầu cho thấy: Tỷ lệ dữ liệu bị thiếu (Missing Values) đối với 7 đặc trưng chính và biến mục tiêu là chính xác 0.0%. Phát hiện và loại bỏ 3 bản ghi trùng lặp hoàn toàn, giữ lại 26,998 bản ghi sạch phục vụ phân tích.


3.7. Phân tích khám phá dữ liệu (EDA)

Quá trình khám phá dữ liệu thực hiện phân tích đa chiều thông qua 8 biểu đồ thực tế trích xuất từ project:




Hình 3. 1: Biểu đồ phân bố mức tiêu hao nhiên liệu kết hợp (L/100 km)

Nhận xét Hình 3.1: Biểu đồ Histogram và đường ước lượng mật độ KDE thể hiện phân bố của biến mục tiêu lệch nhẹ về bên phải (Right-skewed). Đỉnh phân bố tập trung chủ yếu trong khoảng 8.0 đến 12.0 L/100 km, đại diện cho phần lớn các dòng xe phổ thông. Phần đuôi kéo dài về phía 20 - 26 L/100 km tương ứng với các dòng xe có dung tích xi-lanh lớn.




Hình 3. 2: Biểu đồ Boxplot phân bố và nhận diện ngoại lệ của biến mục tiêu

Nhận xét Hình 3.2: Biểu đồ Boxplot xác định giá trị trung vị ở mức khoảng 10.5 L/100 km, khoảng tứ phân kỳ Q1-Q3 nằm trong khoảng 8.5 đến 13.0 L/100 km. Các điểm dữ liệu nằm ngoài ngưỡng 19.5 L/100 km được coi là ngoại lệ (Outliers) về mặt thống kê, tuy nhiên đây là các giá trị thực tế hợp lệ của các dòng siêu xe hoặc xe tải nặng nên được giữ lại để mô hình học tập.




Hình 3. 3: Mối quan hệ giữa Dung tích động cơ (L) và Mức tiêu hao nhiên liệu

Nhận xét Hình 3.3: Biểu đồ tán xạ (Scatter Plot) cho thấy mối quan hệ đồng biến tuyến tính dương rất mạnh giữa dung tích động cơ và mức tiêu thụ nhiên liệu. Động cơ dung tích càng lớn (từ 1.0L đến 8.4L) đòi hỏi lượng nhiên liệu đốt cháy càng nhiều, tạo nên xu hướng tăng rõ rệt.




Hình 3. 4: Mức tiêu hao nhiên liệu phân theo Số lượng xi-lanh

Nhận xét Hình 3.4: Số lượng xi-lanh tỉ lệ thuận với mức tiêu thụ nhiên liệu. Động cơ 3-4 xi-lanh có mức tiêu thụ trung bình thấp nhất (~7.5 - 9.0 L/100 km), trong khi động cơ 8, 10, 12 và 16 xi-lanh có mức tiêu thụ trung bình vượt trội (>15.0 L/100 km).




Hình 3. 5: Mức tiêu hao nhiên liệu theo Phân loại lớp xe (Vehicle Class)

Nhận xét Hình 3.5: Các dòng xe kích thước nhỏ như Compact, Subcompact, Mid-size có mức tiêu thụ tiết kiệm. Trái lại, các phân khúc xe gầm cao, SUV cỡ lớn, Van chở khách và Pickup Truck tiêu tốn nhiều nhiên liệu hơn đáng kể do trọng lượng xe lớn và lực cản khí động học cao.




Hình 3. 6: Mức tiêu hao nhiên liệu theo Loại nhiên liệu sử dụng

Nhận xét Hình 3.6: Nhiên liệu Ethanol E85 (ký hiệu E) có mức tiêu thụ thể tích L/100 km cao nhất do mật độ năng lượng của cồn thấp hơn xăng. Xe sử dụng Diesel (D) và Xăng thường (X) có mức tiêu thụ trung bình tối ưu hơn.



Hình 3. 7: Ma trận tương quan Pearson giữa các đặc trưng số

Nhận xét Hình 3.7: Ma trận tương quan xác nhận hệ số tương quan giữa Dung tích động cơ (Engine Size) và Tiêu thụ nhiên liệu đạt 0.83; giữa Số xi-lanh (Cylinders) và Tiêu thụ nhiên liệu đạt 0.81. Đây là 2 đặc trưng quan trọng nhất trong việc dự đoán biến mục tiêu.



Hình 3. 8: Biểu đồ kiểm tra tỷ lệ dữ liệu khuyết thiếu trên 7 đặc trưng chính

Nhận xét Hình 3.8: Biểu đồ xác nhận toàn bộ 7 đặc trưng đầu vào và biến mục tiêu đều đạt tỷ lệ đầy đủ 100% (0% missing), đảm bảo tính toàn vẹn của dữ liệu trước khi đưa vào mô hình.

3.8. Phân tích biến mục tiêu

Tổng kết phân tích biến mục tiêu: Giá trị trung bình đạt 10.92 L/100 km, trung vị 10.50 L/100 km, độ lệch chuẩn 2.84 L/100 km. Dải giá trị trải dài từ 4.0 đến 26.1 L/100 km. Không cần thực hiện biến đổi Logarithm do phân phân bố không bị lệch quá nghiêm trọng và giữ nguyên đơn vị L/100 km giúp mô hình dễ giải thích kết quả thực tế.

3.9. Phân tích mối quan hệ đặc trưng – mục tiêu

Các mối quan hệ đa chiều giữa đặc trưng đầu vào và biến mục tiêu cho thấy bài toán vừa mang tính tuyến tính mạnh (ở các biến số như Engine Size, Cylinders) vừa mang tính phi tuyến theo nhóm (ở các biến phân loại như Vehicle Class, Fuel Type, Transmission). Điều này đòi hỏi thử nghiệm cả mô hình tuyến tính lẫn các mô hình phi tuyến mạnh như KNN, Decision Tree và SVR.

3.10. Tiền xử lý dữ liệu

Quy trình tiền xử lý được tự động hóa bằng ColumnTransformer trong Scikit-Learn:

1. Xử lý khoảng trống thừa và chuẩn hóa ký tự viết hoa/viết thường đối với các biến chuỗi.
2. Loại bỏ các cột trùng lặp và các thuộc tính gây rò rỉ dữ liệu.
3. Tách biệt tập đặc trưng X và vector mục tiêu y.

3.11. Encoding dữ liệu phân loại

Các đặc trưng phân loại (Make, Vehicle Class, Transmission, Fuel Type) được chuyển đổi sang dạng số bằng kỹ thuật One-Hot Encoding (OHE) với tham số `handle_unknown='ignore'`. Kỹ thuật này tránh việc gán thứ tự giả tạo giữa các thuộc tính danh định.

3.12. Chuẩn hóa dữ liệu

Các đặc trưng số (Engine Size, Cylinders, Model Year) được chuẩn hóa bằng StandardScaler đưa về phân bố có trung bình = 0 và độ lệch chuẩn = 1. Việc chuẩn

hóa là bắt buộc đối với thuật toán KNN (dựa trên khoảng cách) và SVR (dựa trên lề biên) nhằm tránh việc thuộc tính có thang đo lớn áp đảo thuộc tính khác.

3.13. Chia dữ liệu huấn luyện và kiểm tra

Tập dữ liệu 26,998 bản ghi được phân chia ngẫu nhiên theo tỷ lệ 80% Huấn luyện (Training set = 21,598 bản ghi) và 20% Kiểm tra (Test set = 5,400 bản ghi) với giá trị `random_state` cố định bằng 42 để bảo đảm khả năng tái lập kết quả thử nghiệm.

3.14. Tránh Data Leakage trong tiền xử lý

Để bảo đảm tính nguyên tắc, toàn bộ các tham số chuẩn hóa (trung bình, độ lệch chuẩn của `StandardScaler`) và từ điển mã hóa (`OneHotEncoder`) chỉ được tính toán (fit) duy nhất trên tập Huấn luyện (Train set). Tập Kiểm tra (Test set) hoàn toàn không tham gia vào quá trình này và chỉ được áp dụng thao tác biến đổi (transform), đảm bảo đánh giá vô tư nhất.

CHƯƠNG 4: XÂY DỰNG, HUẤN LUYỆN VÀ ĐÁNH GIÁ MÔ HÌNH

4.1. Quy trình xây dựng mô hình

Quy trình huấn luyện và đánh giá mô hình được thiết kế chặt chẽ: Dữ liệu sạch -> Pipeline tiền xử lý -> Chia tập 80/20 -> Huấn luyện 4 thuật toán -> Tính chỉnh siêu tham số qua 5-Fold Cross Validation trên tập Train -> Đánh giá độc lập trên tập Test -> Lựa chọn mô hình Production.

4.2. Mô hình cơ sở (Baseline Model)

Project xây dựng mô hình cơ sở DummyRegressor dự đoán mọi mẫu bằng giá trị trung bình y_{train} . Kết quả baseline trên tập Test đạt $MAE = 2.2145$ L/100 km, $RMSE = 2.8251$ L/100 km, $R^2 = 0.0000$. Đây là mốc tối thiểu để các mô hình học máy bắt buộc phải vượt qua.

4.3. Linear Regression

Huấn luyện mô hình Hồi quy tuyến tính (Linear Regression) đóng vai trò mô hình tham chiếu tuyến tính đơn giản. Mô hình hoàn thành huấn luyện tức thì (0.19 giây).

4.4. Decision Tree Regressor

Thử nghiệm mô hình Cây quyết định (Decision Tree Regressor) với không gian tìm kiếm GridSearchCV:

- max_depth: [5, 10, 15, 20]
- min_samples_split: [2, 5, 10]
- min_samples_leaf: [1, 2, 4]

Cấu hình tối ưu được lựa chọn qua CV là: max_depth = 20, min_samples_split = 10, min_samples_leaf = 1. Điểm MAE CV đạt 0.4888 L/100 km.

4.5. KNN Regression

Thử nghiệm mô hình K láng giềng gần nhất (KNN Regressor) với không gian tìm kiếm GridSearchCV:

- n_neighbors: [3, 5, 7, 9]
- weights: ['uniform', 'distance']

- p: [1, 2] (1: Manhattan Distance, 2: Euclidean Distance)

Cấu hình tối ưu được lựa chọn qua CV là: n_neighbors = 5, weights = 'distance', p = 1 (Manhattan Distance). Điểm MAE CV đạt 0.4690 L/100 km.

4.6. Support Vector Regression

Thử nghiệm mô hình Hồi quy Vector hỗ trợ (SVR) với không gian tìm kiếm GridSearchCV:

- C: [1.0, 10.0]
- epsilon: [0.1]
- kernel: ['rbf']
- gamma: ['scale']

Cấu hình tối ưu được lựa chọn qua CV là: C = 10.0, epsilon = 0.1, kernel = 'rbf', gamma = 'scale'. Điểm MAE CV đạt 0.4512 L/100 km.

4.7. Bảng siêu tham số thử nghiệm và được chọn

Mô hình	Siêu tham số tinh chỉnh	Các giá trị thử nghiệm	Giá trị tối ưu được chọn
Linear Regression	fit_intercept	[True, False]	fit_intercept = True
Decision Tree	max_depth, min_samples_split, min_samples_leaf	depth:[5,10,15,20], split:[2,5,10], leaf:[1,2,4]	max_depth=20, min_samples_split=10, min_samples_leaf=1
KNN Regressor	n_neighbors, weights, p	k:[3,5,7,9], w:['uniform','distance'], p:[1,2]	n_neighbors=5, weights='distance', p=1
SVR	C, epsilon, kernel, gamma	C:[1.0, 10.0], eps:[0.1], kernel:['rbf']	C=10.0, epsilon=0.1, kernel='rbf', gamma='scale'

4.8. Kết quả Cross Validation

Kiểm định chéo 5-Fold Cross Validation trên tập Huấn luyện cho thấy các mô hình phi tuyến đều thể hiện độ ổn định cao. Điểm MAE CV trung bình của SVR đạt 0.4512 (+/- 0.012), KNN đạt 0.4690 (+/- 0.015), Decision Tree đạt 0.4888 (+/- 0.018).

4.9. Tiêu chí đánh giá

Đánh giá chính thức trên tập Kiểm tra độc lập (Test set = 5,400 bản ghi) sử dụng 4 chỉ số: MAE (L/100 km), MSE, RMSE (L/100 km) và hệ số R^2 .

4.10. Kết quả Linear Regression

- MAE: 0.7839 L/100 km
- MSE: 1.1038
- RMSE: 1.0506 L/100 km
- R^2 Test: 0.8909 (89.09%) | R^2 Train: 0.8944

4.11. Kết quả Decision Tree Regressor

- MAE: 0.4665 L/100 km
- MSE: 0.4793
- RMSE: 0.6923 L/100 km
- R^2 Test: 0.9526 (95.26%) | R^2 Train: 0.9744

4.12. Kết quả KNN Regression

- MAE: 0.4351 L/100 km
- MSE: 0.4404
- RMSE: 0.6637 L/100 km
- R^2 Test: 0.9565 (95.65%) | R^2 Train: 0.9858


4.13. Kết quả Support Vector Regression

- MAE: 0.4293 L/100 km
- MSE: 0.4222
- RMSE: 0.6498 L/100 km
- R^2 Test: 0.9583 (95.83%) | R^2 Train: 0.9677

4.14. Bảng so sánh tổng hợp 4 mô hình

Mô hình	MAE (L/100km)	MSE	RMSE (L/100km)	R^2 Test	R^2 Train	Thời gian suy luận	Kích thước tập
---------	------------------	-----	-------------------	------------	-------------	--------------------------	----------------------


Linear Regression	0.7839	1.1038	1.0506	0.8909	0.8944	0.024 s	6.3 KB
Decision Tree	0.4665	0.4793	0.6923	0.9526	0.9744	0.026 s	613.4 KB
KNN Regressor	0.4351	0.4404	0.6637	0.9565	0.9858	1.022 s	2,030.6 KB
SVR (RBF Kernel)	0.4293	0.4222	0.6498	0.9583	0.9677	6.569 s	1,798.2 KB



Hình 4. 1: Biểu đồ so sánh hiệu năng MAE, RMSE và R^2 giữa 4 mô hình

Nhận xét Hình 4.1: Biểu đồ so sánh trực quan khẳng định SVR đạt hiệu năng toàn diện nhất với MAE và RMSE thấp nhất, đồng thời R^2 cao nhất (95.83%), vượt trội hơn hẳn so với Linear Regression (89.09%).


4.15. Phân tích Actual vs Predicted



Hình 4. 2: Biểu đồ so sánh giữa Giá trị thực tế (Actual) và Giá trị dự đoán (Predicted)

Nhận xét Hình 4.2: Các điểm biểu diễn giá trị dự đoán của SVR và KNN phân bố bám rất sát đường phân giác lý tưởng $y = x$. Độ lệch xuất hiện rất ít và chủ yếu nằm ở dải mức tiêu thụ cực cao (> 20 L/100 km).

4.16. Residual Analysis (Phân tích phần dư)



Hình 4. 3: Biểu đồ phân tích phần dư ($\text{Residual} = \text{Actual} - \text{Predicted}$) theo giá trị dự đoán

Nhận xét Hình 4.3: Biểu đồ phần dư Residual Plot cho thấy các điểm sai số của SVR phân bố đối xứng và đồng đều quanh trục hoành 0. Không xuất hiện hiện tượng biến đổi phương sai (Heteroscedasticity) hay mẫu hình phi tuyến bất thường.

4.17. Phân tích Overfitting / Underfitting

So sánh R^2 Train và R^2 Test giữa các mô hình:

- Linear Regression (Train 0.8944 / Test 0.8909): Không overfitting nhưng underfitting nhẹ do mô hình quá đơn giản.
- Decision Tree (Train 0.9744 / Test 0.9526) & KNN (Train 0.9858 / Test 0.9565): Có dấu hiệu quá khớp nhẹ do điểm train cao vượt trội điểm test.
- Support Vector Regression (Train 0.9677 / Test 0.9583): Đạt sự cân bằng lý tưởng nhất, khoảng cách chênh lệch giữa Train và Test cực nhỏ (< 0.01), chứng tỏ khả năng tổng quát hóa (Generalization) tuyệt vời.

4.18. So sánh 4 mô hình

Đánh giá tổng hợp: SVR chiến thắng tuyệt đối về chỉ số sai số tuyệt đối MAE (0.4293 L/100 km) và hệ số R^2 (0.9583). Tuy thời gian suy luận trên tập Test của SVR (6.57s cho 5,400 mẫu ~ 1.2ms/mẫu) lâu hơn so với Decision Tree, nhưng tốc độ này hoàn toàn đáp ứng thời gian thực đối với từng yêu cầu đơn lẻ.

4.19. Lựa chọn mô hình cuối

Dựa trên các bằng chứng thực nghiệm đầy đủ, mô hình **Support Vector Regression (SVR)** được chọn làm mô hình chính thức (Production Model) để đóng gói và tích hợp vào hệ thống phần mềm dự đoán.

CHƯƠNG 5: XÂY DỰNG HỆ THỐNG, KIỂM THỬ VÀ KẾT LUẬN

5.1. Tích hợp mô hình vào hệ thống

Sau khi huấn luyện và chọn lựa mô hình SVR đạt kết quả tối ưu, mô hình được xuất dưới dạng tệp đóng gói hoàn chỉnh bao gồm cả Pipeline tiền xử lý (Encoder + Scaler) và mô hình hồi quy. Mô hình này được nạp vào một dịch vụ trí tuệ nhân tạo chuyên biệt để sẵn sàng phục vụ dự đoán.

5.2. Kiến trúc tổng thể

Hệ thống được thiết kế theo kiến trúc đa tầng hiện đại (Multi-tier Architecture):

1. Tầng Giao diện người dùng (Web Frontend): Cung cấp giao diện biểu mẫu tương tác cho người dùng nhập thông số xe và hiển thị kết quả dự đoán trực quan.
2. Tầng Nghiệp vụ (Backend API Service): Tiếp nhận yêu cầu, kiểm tra tính hợp lệ của dữ liệu đầu vào (Validation), gắn mã định danh giao dịch (Request ID), điều phối lời gọi sang AI Service và lưu vết lịch sử.
3. Tầng Dự đoán AI (AI Prediction Service): Nạp mô hình SVR đã đóng gói, thực hiện tiền xử lý vector thuộc tính và trả về kết quả tiêu thụ nhiên liệu dự đoán.
4. Tầng Lưu trữ (Database Service): Lưu trữ nhật ký giao dịch dự đoán và danh mục dữ liệu cấu hình.

5.3. Giao diện nhập thông tin xe

Giao diện người dùng cung cấp các trường nhập liệu tương ứng chính xác với 7 đặc trưng đầu vào:

- Năm sản xuất (Model Year): Ô chọn danh sách năm từ 1995 đến 2023.
- Hãng sản xuất (Make): Danh sách chọn 55 hãng xe (Toyota, Honda, Ford, BMW...).
- Phân loại xe (Vehicle Class): Danh sách chọn 25 kiểu dáng xe (Compact, SUV, Pickup...).
- Dung tích động cơ (Engine Size): Ô nhập số thực tính theo Lít (ví dụ: 2.5 L).
- Số lượng xi-lanh (Cylinders): Ô chọn số nguyên (4, 6, 8...).

- Loại hộp số (Transmission): Ô chọn mã hộp số (A6, AS6, M6, AV...).
- Loại nhiên liệu (Fuel Type): Ô chọn loại nhiên liệu (Xăng thường, Xăng cao cấp, Diesel, E85).

5.4. Quy trình dự đoán

Quy trình dự đoán diễn ra qua 5 bước tự động:

Người dùng nhập thông tin -> Backend xác thực hợp lệ -> AI Service chuẩn hóa & đưa vào mô hình SVR -> Mô hình tính toán ra kết quả L/100 km -> Backend lưu lịch sử & Frontend hiển thị kết quả.

5.5. Ý nghĩa kết quả dự đoán

Kết quả dự đoán được trả về dưới dạng số thực kèm đơn vị chuẩn Lít/100 km. Ví dụ, khi người dùng nhập thông số xe Toyota Camry 2.5L, mô hình trả về kết quả dự đoán 8.35 L/100 km. Con số này có ý nghĩa: Trong điều kiện vận hành kết hợp tiêu chuẩn (45% cao tốc + 55% thành phố), chiếc xe được dự báo tiêu thụ khoảng 8.35 lít nhiên liệu trên quãng đường 100 km.

5.6. Triển khai hệ thống

Hệ thống được tổ chức triển khai độc lập theo các dịch vụ thành phần độc lập (Containerized Services), bảo đảm tính đóng gói và sẵn sàng nâng cấp hoặc tái huấn luyện mô hình mà không ảnh hưởng tới giao diện người dùng.

5.7. Kiểm thử dữ liệu hợp lệ

Thực hiện 5 kịch bản kiểm thử với dữ liệu nhập hợp lệ (các dòng xe Sedan 2.0L, SUV 3.5L, Pickup 5.0L). Tất cả các trường hợp đều trả về kết quả dự đoán hợp lý nằm trong khoảng [5.5, 18.2] L/100 km với thời gian phản hồi dưới 50ms.

5.8. Kiểm thử dữ liệu không hợp lệ

Thực hiện kiểm thử các trường hợp dữ liệu bất thường (thiếu trường thông tin, nhập dung tích động cơ âm, gán loại nhiên liệu không tồn tại). Hệ thống thực hiện bắt lỗi chính xác ở tầng Backend và trả về thông báo hướng dẫn rõ ràng cho người dùng mà không gây sự cố dừng dịch vụ.

5.9. Kiểm thử hệ thống tổng thể

Thực hiện kiểm thử tích hợp toàn trình (End-to-End Integration Test) từ thao tác bấm nút dự đoán trên giao diện web đến khi nhận phản hồi kết quả và kiểm tra bản ghi tương ứng được ghi nhận thành công trong cơ sở dữ liệu.

5.10. Kiểm thử hiệu năng

Thực hiện kiểm thử hiệu năng đơn lẻ và tải nhẹ. Thời gian trung bình để xử lý 1 yêu cầu dự đoán từ lúc nhận dữ liệu đến khi trả kết quả đạt trung bình 35ms - 45ms, bảo đảm trải nghiệm mượt mà cho người sử dụng.

5.11. Kết quả đạt được

1. Xây dựng hoàn chỉnh báo cáo và hệ thống dự đoán mức tiêu hao nhiên liệu dựa trên dữ liệu thực tế 26,998 bản ghi.
2. Thực hiện EDA đa chiều với 8 biểu đồ phân tích chuyên sâu.
3. Đã thử nghiệm, so sánh và tinh chỉnh thành công 4 thuật toán hồi quy kinh điển.
4. Mô hình SVR được chọn đạt hiệu năng xuất sắc: $MAE = 0.4293$ L/100 km, $RMSE = 0.6498$ L/100 km, $R^2 = 95.83\%$.
5. Tích hợp thành công mô hình vào hệ thống phần mềm ứng dụng hoàn chỉnh có khả năng kiểm thử dữ liệu thực tế.

5.12. Hạn chế

- Dữ liệu mang tính lịch sử kiểm định tiêu chuẩn (Chính phủ Canada), chưa phản ánh đầy đủ các yếu tố thực tế như thói quen bảo dưỡng, tải trọng chở thêm hoặc tình trạng kẹt xe đô thị đặc thù tại Việt Nam.
- Mô hình chưa xem xét các thuộc tính kỹ thuật chuyên sâu như hệ số cản khí động học (Cd) hoặc chỉ số tỷ số nén của động cơ.

5.13. Hướng phát triển

- Thu thập và bổ sung dữ liệu các dòng xe điện (EV) và xe Hybrid thế hệ mới.
- Thử nghiệm thêm các thuật toán học máy nâng cao như Gradient Boosting (XGBoost, LightGBM) hoặc mạng nơ-ron nhân tạo (ANN).

- Phát triển thêm tính năng giải thích mô hình (Explainable AI - SHAP/LIME) giúp người dùng hiểu rõ thuộc tính nào đóng góp nhiều nhất vào mức tiêu thụ nhiên liệu của chiếc xe.

5.14. Kết luận chung

Đề tài 'Dự đoán mức tiêu hao nhiên liệu của xe' đã hoàn thành đầy đủ 100% các mục tiêu và yêu cầu đề ra. Quá trình thực hiện từ nghiên cứu lý thuyết, phân tích dữ liệu thực tế, xây dựng huấn luyện mô hình đến tích hợp hệ thống đều được triển khai khoa học, nghiêm túc và mang lại giá trị ứng dụng thực tiễn cao.

PHÂN CÔNG CÔNG VIỆC

Bảng phân công nhiệm vụ chi tiết của các thành viên trong nhóm thực hiện đề tài:

STT	Thành viên thực hiện	Mã sinh viên	Nhiệm vụ phân công
1	[HỌ TÊN SINH VIÊN 1]	[MÃ SV 1]	Thu thập dữ liệu, thực hiện phân tích EDA (8 biểu đồ), viết Chương 1 & Chương 3.
2	[HỌ TÊN SINH VIÊN 2]	[MÃ SV 2]	Tiền xử lý dữ liệu, xây dựng Pipeline, huấn luyện 4 mô hình, tinh chỉnh GridSearchCV.
3	[HỌ TÊN SINH VIÊN 3]	[MÃ SV 3]	Đánh giá so sánh 4 mô hình, tích hợp AI Service, kiểm thử hệ thống & viết Chương 4, 5.

TÀI LIỆU THAM KHẢO

- [1] Government of Canada, "Official Fuel Consumption Ratings 1995-2023", Open Data Canada / Kaggle Dataset, 2023.
- [2] Pedregosa, F., et al., "Scikit-learn: Machine Learning in Python", Journal of Machine Learning Research, vol. 12, pp. 2825-2830, 2011.
- [3] Gareth James, Daniela Witten, Trevor Hastie, Robert Tibshirani, "An Introduction to Statistical Learning: with Applications in R", Springer, 2013.
- [4] Christopher M. Bishop, "Pattern Recognition and Machine Learning", Springer, 2006.
- [5] Aurélien Géron, "Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow", O'Reilly Media, 2nd Edition, 2019.
- [6] Alex Smola, Bernhard Schölkopf, "A tutorial on support vector regression", Statistics and Computing, vol. 14, pp. 199-222, 2004.

PHỤ LỤC

Phụ lục cung cấp bảng thống kê mô tả chi tiết của các thuộc tính số trong tập dữ liệu 26,998 bản ghi:

Thuộc tính số	Trung bình (Mean)	Độ lệch chuẩn (Std)	Trung vị (Median)	Giá trị Min	Giá trị Max
Engine Size (L)	3.16 L	1.35 L	3.00 L	0.80 L	8.40 L
Cylinders	5.62	1.95	6.00	2.00	16.00
Fuel Consumption Comb	10.92 L/100km	2.84 L/100km	10.50 L/100km	4.00 L/100km	26.10 L/100km